Universidad de Costa Rica
Curso: Herramientas de Datos I

Turismo en Costa Rica

Llegadas internacionales y visitas a áreas silvestres protegidas

Integrantes
Felipe Pereira Fallas Kevin Arias Reyes
Sebastián Mora Rojas Jerald Valverde Mora

7 de noviembre de 2026

Introducción

Las llegadas internacionales de turistas y las visitas a áreas silvestres protegidas describen flujos distintos del turismo en Costa Rica: entradas al país y registros de uso de espacios naturales. Caracterizar cuándo aumenta o disminuye cada flujo aporta información para planificar servicios turísticos y la gestión de áreas protegidas. La comparación también tiene interés estadístico porque permite contrastar la estacionalidad y la asociación entre ambas series. Como los datos están agregados por mes, describen patrones conjuntos, pero no prueban causalidad ni identifican personas únicas detrás de cada visita.

El análisis utiliza registros mensuales de llegadas internacionales y de visitas de residentes y no residentes a áreas protegidas. La base de llegadas cubre 2013–2025 y la de visitas, 2013–2024; el análisis conjunto utiliza el período común 2013–2024, equivalente a 144 meses. El código calcula índices estacionales, tendencias y variaciones interanuales, y examina la asociación entre series mediante correlaciones y modelos lineales. Algunas comparaciones distinguen los períodos 2013–2019 y 2022–2024 y excluyen 2020–2021.

El repositorio atribuye ambas bases al Instituto Costarricense de Turismo (ICT). El ICT publica la serie de llegadas internacionales con información de la Dirección General de Migración y Extranjería. Para las visitas a áreas silvestres protegidas, publica la serie mensual y atribuye la fuente a la Gerencia de Áreas Silvestres Protegidas del SINAC.

Objetivo general

Pronosticar, para los próximos 12 meses, las llegadas mensuales de turistas internacionales a Costa Rica y las visitas totales a áreas silvestres protegidas, utilizando sus series históricas y seleccionando para cada una el modelo con menor RMSE de validación.

Metodología

Obtención y tratamiento de los datos.

Se usaron dos series mensuales del Instituto Costarricense de Turismo (ICT): las llegadas internacionales de turistas por todas las vías, de 2013 a 2025 (156 observaciones; ICT, 2025b), y las visitas totales de residentes y no residentes a áreas silvestres protegidas, de 2013 a 2024 (144 observaciones; ICT, 2025a). Ambas se publican en PDF, por lo que se extrajeron en `R` con `pdftools`: `pdf_data()`. Dado a la falta de algunos valores numéricos durante la extracción, se reconstruyeron usando la relación de visitantes residentes y no residentes, con el total; asi como las llegadas de turistas de

cada bloque numérico. Esta información se organizó en dos bases, juntando el año y mes con sus indicadores.

Preparación de las series

Se usaron las series mensuales de llegadas internacionales (enero,2013 a diciembre,2025: 156 observaciones) y de visitas totales (enero,2013 a diciembre,2024: 144 observaciones). Se modelaron de forma independiente y univariante, a partir del comportamiento de su propio pasado. Antes de 2020, las series presentan una tendencia creciente, así como, una estacionalidad marcada. Los modelos se ajustaron sobre el logaritmo natural, esto porque estabiliza la varianza, vuelve aditiva a la estacionalidad proporcional y garantiza que los resultados obtenidos sean positivos. El ingenuo se ajusta en la escala original. En adelante, $y_t^* = \log(y_t)$ denota la serie transformada.

Hay un punto de quiebre, las series tienen una caída por la Pandemia, los meses en los que esta ocurre que incorporan sin tratamiento, para que los modelos interpreten este efecto como parte de la dinamica normal de la serie; por esto se marcaron los meses que comprendió la pandemia como faltantes (marzo-2020, Diciembre-2022), además, se estimó un ARIMA estacional con los datos restantes, mediante el filtro de Kalman, que admite observaciones faltantes. Por otra parte, los meses faltantes se reemplazan con `interpolate()`. El fin de la ventana es un criterio de juicio, en 2022 las llegadas seguían cerca del 80 % del nivel de 2019, y desde 2023 la serie parece estabilizarse en un nivel nuevo. Por eso el pronóstico describe lo esperable dada la dinámica previa y la recuperación, no un nuevo choque.

Modelos

Se ajustaron cuatro modelos por serie, a los que se les agrega una referencia ingenua que no compite por ser seleccionada, los tres primeros parten de supuestos distintos, el cuarto combina:

ETS (suavizamiento exponencial con espacio de estados)

descompone la serie en componentes no observables (nivel, tendencia y estacionalidad) que se actualizan mes a mes, con más peso a lo reciente. Su especificación se elige por AICc. Con $m = 12$ como periodo estacional.

ARIMA estacional

Explica cada valor con valores y errores de meses anteriores. Sus órdenes se eligen con el algoritmo de Hyndman y Khandakar (2008).

Regresión con tendencia y estacionalidad (TSLM)

El modelo de regresión lineal ajusta una tendencia lineal en el tiempo más variables indicadoras de mes, donde t es el índice de tiempo y $D_{j,t}$ indica si la observación corresponde al mes j (enero es la categoría de referencia). En logaritmos, la pendiente β_1 equivale a un crecimiento porcentual constante.

$$y_t^* = \beta_0 + \beta_1\, t + \sum_{j=2}^{12} \gamma_j\, D_{j,t} + \varepsilon_t$$

Combinación de modelos

El modelo combinado es el promedio aritmético de los tres anteriores:

$$\widehat{y}_{t+h}^{comb} = \tfrac{1}{3}\left(\widehat{y}_{t+h}^{ETS} + \widehat{y}_{t+h}^{ARIMA} + \widehat{y}_{t+h}^{TSLM}\right)$$

Referencia ingenua estacional

Como punto de comparación se incluye el método ingenuo estacional, que pronostica para cada mes el valor observado en ese mismo mes del año anterior:

$$\widehat{y}_{t+h} = y_{t+h-m\,(k+1)}, \qquad m = 12$$

donde k es el número de años completos contenidos en el horizonte h. No estima parámetros ni supone una forma funcional: simplemente repite el último ciclo anual observado. Fija el umbral mínimo de desempeño, Hyndman y Athanasopoulos (2021) recomiendan reportar siempre al menos un método de referencia de este tipo, ya que una métrica de error carece de interpretación sin un punto de comparación. Por esta razón el método ingenuo se ajusta y evalúa en las mismas condiciones que los demás, pero se excluye de la selección.

Validación y selección

En los últimos 24 meses, en cada serie se reservan como conjunto de prueba las llegadas en 2024-2025 t 2023-2024 en visitas, dejando por fuera el COVID. Los modelos se ajustan con los datos anteriores; además, se pronostican esos 24 meses y se calcula cada error correspondiente $e_t = y_t - \widehat{y}_t$:

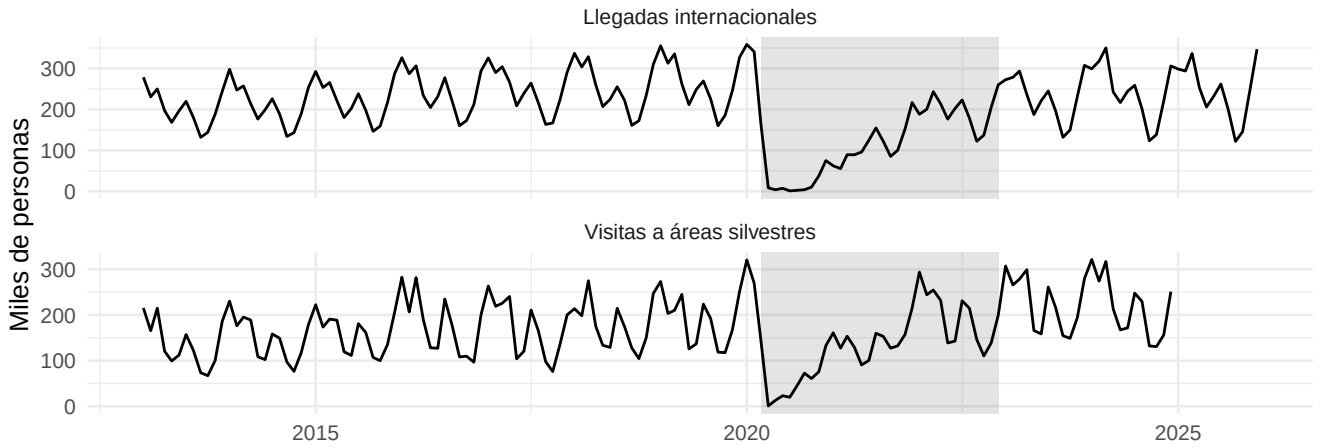
$$\text{RMSE} = \sqrt{\tfrac{1}{n}\sum e_t^2}, \qquad \text{MAE} = \tfrac{1}{n}\sum |e_t|, \qquad \text{MAPE} = \tfrac{100}{n}\sum \left|\tfrac{e_t}{y_t}\right|$$

Se considera como criterio de seleccion el menor `RSME` entre los cuatro modelos, esto porque entre más alto el error, más lo penaliza. Por otra parte, MAE y MAPE se usan como complemento para finiquitar esta consideración. El ingenuo se evalúa de la misma manera pero no se considera en la seleción, continuando, el modelo elegido se reajustó con la serie completa y se genera el pronóstico de 12 meses con intervalos de predicción del 95 %.

Resultados

Comportamiento de las dos series

Figura 1: Llegadas internacionales de turistas y visitas totales a áreas silvestres protegidas, datos mensuales. La franja gris marca el periodo tratado como atípico (marzo 2020 a diciembre 2022).



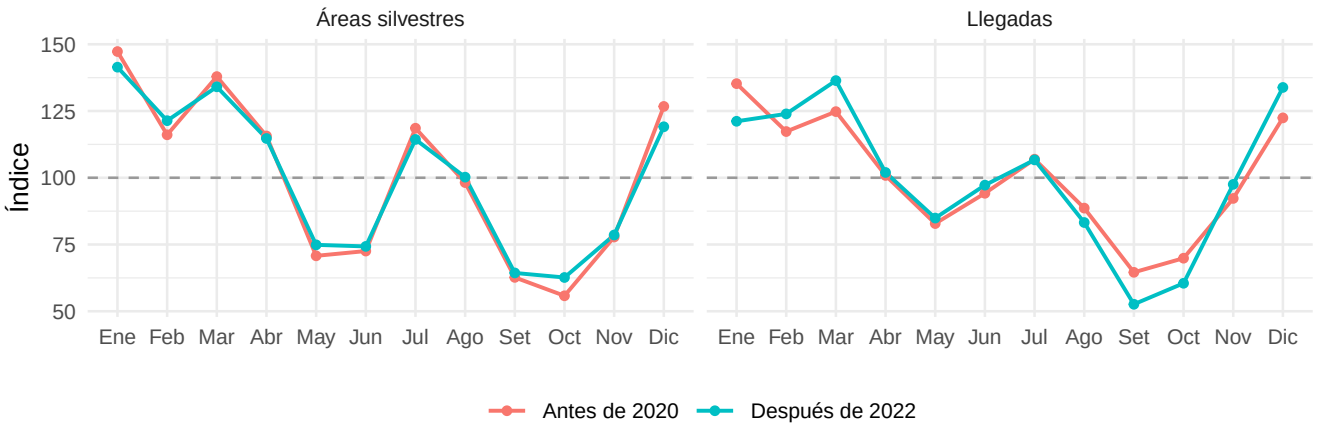
Fuente: elaboración propia con datos del Instituto Costarricense de Turismo.

La Figura 1 muestra que las dos series se comportan de forma parecida. Las dos crecen hasta 2019, caen de golpe en 2020 y vuelven a subir desde 2022. También se ve el patrón que se repite todos los años: picos a inicio de año y valles a mitad del segundo semestre.

La caída de 2020 no es un dato aislado, es un quiebre. Por eso no se puede tratar como un valor atípico cualquiera. La franja gris indica los 34 meses que la metodología marcó como faltantes y luego rellenó. Esto importa para el objetivo porque un modelo que aprendiera esa caída como parte del comportamiento normal pronosticaría una tendencia hacia abajo que no corresponde.

La estacionalidad es el patrón que manda

Figura 2: Índice estacional antes y después de la pandemia. El valor 100 equivale a un mes promedio de su propio año.



Fuente: elaboración propia con datos del Instituto Costarricense de Turismo.

En la Figura 2 se observa que el mes más alto de las llegadas (Ene) vale 2.09 veces el más bajo (Set) en el periodo 2013-2019. En las áreas silvestres esa razón es de 2.64. O sea, la visitación a parques es todavía más estacional que las llegadas al país.

Esto ocurre porque el turismo de naturaleza depende del clima mucho más que el resto. Los meses bajos son setiembre y octubre, que son los más lluviosos. Un turista que viene en esa época hace otras actividades.

La implicación para el objetivo es directa: si la estacionalidad explica tanto de la serie, cualquier modelo que la capture bien ya va a acertar bastante. Eso sube la vara de lo que significa un buen pronóstico, y por eso más adelante se compara contra una referencia simple.

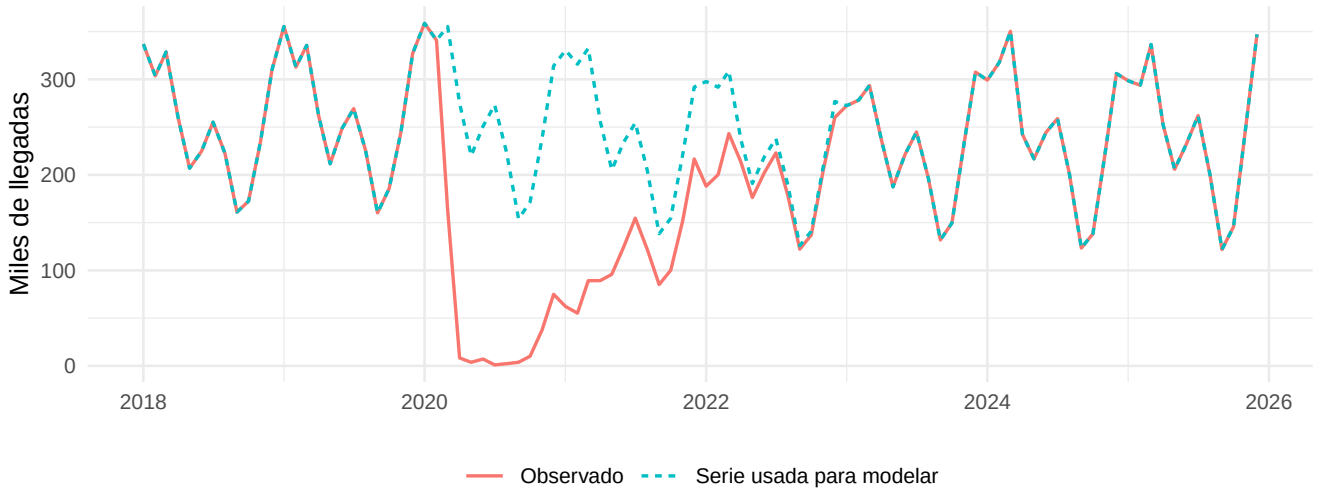
La Tabla 3 muestra algo que no se ve a simple vista en el gráfico: el patrón estacional **cambió** después de la pandemia. La amplitud pasó de 2.09 a 2.59. No es el mismo calendario de antes.

La causa probable es un cambio en quién visita el país. Entre 2019 y 2025 el mercado terrestre centroamericano se redujo de forma marcada y subió el peso del turista que llega en avión, que viaja en otras fechas. La implicación es una limitación del modelo: si la estacionalidad no es estable, estimarla con toda la serie mezcla dos comportamientos distintos.

Lo llamativo es que las dos series se movieron en sentidos contrarios. La amplitud de las llegadas pasó de 2.09 a 2.59, o sea que el año se concentró más. La de las áreas silvestres hizo lo opuesto: bajó de 2.64 a 2.26, es decir que se aplanó. Una explicación razonable es que esta segunda serie suma residentes y no residentes, y los residentes visitan los parques según el calendario costarricense (vacaciones de enero, Semana Santa, julio) y no según la temporada seca turística. Si el peso de cada grupo cambió, la estacionalidad del total cambia aunque la de cada grupo por separado siga igual. Esto es importante para el objetivo porque significa que las dos series no se pueden tratar como si respondieran al mismo fenómeno.

Qué tanto pesa el relleno del periodo COVID

Figura 3: Llegadas observadas y valores estimados para el periodo marzo 2020 - diciembre 2022.



Fuente: elaboración propia con datos del Instituto Costarricense de Turismo.

La Figura 3 compara lo que realmente pasó con la serie que se usó para ajustar los modelos. La diferencia es enorme, y eso hay que decirlo claro: durante esos meses el modelo no aprende de datos reales, aprende de una estimación de lo que habría pasado sin pandemia. Esa estimación es posible porque el modelo se formula en espacio de estados y se estima con el filtro de Kalman, que admite observaciones faltantes sin descartar el resto de la serie (Durbin y Koopman, 2012). La alternativa clásica para un choque de este tipo es el análisis de intervención, que conserva los datos reales y agrega una variable que marca el periodo afectado (Box y Tiao, 1975); se retoma en las limitaciones.

Esto tiene un costo distinto en cada serie. En las llegadas, los meses rellenados son 25.8 % del periodo de entrenamiento usado en la validación. En las visitas a áreas silvestres son 28.3 %, y además son los últimos meses de ese periodo. Es decir, para las áreas silvestres el modelo prácticamente no vio datos reales posteriores a la pandemia antes de tener que pronosticarlos.

La implicación es que los resultados de las áreas silvestres hay que leerlos con más cuidado que los de las llegadas.

Validación: qué tan bien pronostica cada modelo

Tabla 1: Error de pronóstico sobre los 24 meses reservados (2024-2025), llegadas internacionales. Menor es mejor.

Modelo	RMSE	MAE	MAPE (%)
ets	13 931	10 870	4.7
combinado	16 047	14 124	6.7
arima	16 790	15 025	7.2
tslm	22 609	19 154	9.3
ingenuo	23 444	18 860	7.3

Fuente: elaboración propia.

Tabla 2: Error de pronóstico sobre los 24 meses reservados (2023-2024), visitas a áreas silvestres.

Modelo	RMSE	MAE	MAPE (%)
ingenuo	18 103	14 129	6.6
ets	20 196	15 229	7.0
combinado	26 902	21 366	9.5
arima	30 008	24 768	11.1
tslm	33 819	27 834	12.3

Fuente: elaboración propia.

En las Tabla 1 y Tabla 2 se agregó un quinto modelo que no estaba en la lista original: el **ingenuo estacional**, que pronostica para cada mes exactamente lo mismo que se observó en ese mismo mes del año anterior. No tiene parámetros ni supuestos. Se incluye porque un modelo solo demuestra que sirve si le gana a la alternativa más barata disponible. Hyndman y Athanasopoulos (2021) recomiendan reportar siempre al menos un método de referencia de este tipo, porque una métrica de error no se puede interpretar en abstracto.

Para las llegadas el mejor modelo fue **ets**, con un RMSE de 13 931 y un MAPE de 4.7 %. Ese MAPE se lee así: en promedio el modelo se equivocó alrededor de un 4.7 % en cada mes de los dos años que no vio al ajustarse.

El ingenuo obtuvo un RMSE de 23 444 y un MAPE de 7.3 %. El modelo elegido sí superó a la referencia: redujo el error en 40.6 %. Esto es lo que permite afirmar que el modelo aporta algo. Sin esta comparación, un MAPE de 4.7 % no se podría interpretar, porque no habría forma de saber si es bueno o si cualquier regla simple habría dado lo mismo.

En las áreas silvestres pasa lo contrario, ahí el mejor de los cuatro modelos también fue **ets**, pero no logró superar al ingenuo: su RMSE fue 11.6 % mayor (20 196 contra 18 103). El ingenuo quedó en la posición 1 de 5.

Reportarlo a mi parecer es de significancia, porque la causa está identificada y es la misma que se mostró en la Figura 3. Para esta serie el periodo de prueba empieza en enero de 2023, de modo que el entrenamiento termina en diciembre de 2022, que es el último mes rellenado. Dicho de otra forma: los modelos nunca vieron un dato real posterior a la pandemia antes de tener que pronosticar dos años. Estimaron tendencia y estacionalidad sobre valores que son una estimación de lo que habría ocurrido sin pandemia, y proyectaron un crecimiento que no se dio. El método ingenuo, al repetir el último ciclo sin añadir tendencia, resultó menos sensible a ese problema.

La conclusión honesta es que, con los datos disponibles, no se puede justificar un modelo sofisticado para esta serie. El pronóstico que sigue se reporta como escenario, no como la mejor estimación posible, y el método ingenuo es una referencia igualmente defendible.

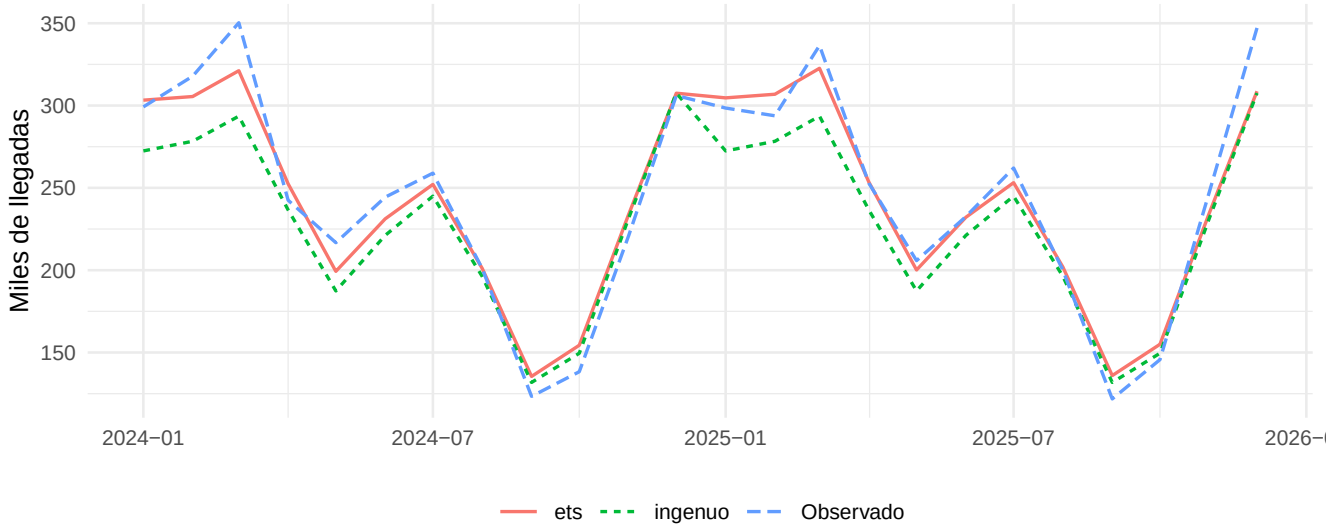
Ahora bien, ETS gana ya que este modelo va actualizando el nivel y la tendencia mes a mes, y les da más peso a los datos recientes (Hyndman et al., 2008). Esa es justamente la característica que sirve acá: después de la pandemia el turismo se estabilizó en un nivel distinto al de antes, y un modelo que se adapta rápido lo capta mejor que uno que supone una estructura fija para toda la serie.

¿Por qué el peor fue tslm? La regresión impone una tendencia lineal única estimada sobre todos los años, incluidos los meses rellenados. Esa recta no representa bien el cambio de nivel que hubo entre 2019 y 2023, y el error se arrastra hacia los años de prueba. Entre el mejor y el peor modelo hay una diferencia de 62.3 % en el RMSE, lo que confirma que valía la pena comparar y no escoger uno de entrada.

A su vez, el ingenuo quedó en la posición 5 de 5 según el RMSE, pero en la 4 según el MAE y el MAPE. Es decir, su error típico no es el peor; lo que lo hunde son unos pocos meses con fallos grandes, que el RMSE castiga más por elevar al cuadrado. Hyndman y Koehler (2006) advierten justamente que el orden de los modelos puede cambiar según la métrica elegida, y que conviene escogerla según el costo que tenga el error en el problema concreto. Esto importa para el objetivo: si lo que preocupa es no quedarse corto en un mes puntual de temporada alta, el RMSE es la métrica correcta, y por eso se usó como criterio de selección.

El modelo combinado obtuvo un RMSE 15.2 % más alto que el mejor de sus componentes, pero 9.7 % más bajo que el promedio de los tres. Eso es exactamente lo que predicen Bates y Granger (1969) y Clemen (1989): promediar protege contra elegir un mal modelo, pero no supera al mejor cuando este se identifica con claridad. Como acá sí se pudo identificar mediante validación, se prefiere el modelo individual.

Figura 4: Llegadas observadas contra lo pronosticado por el mejor modelo y por la referencia ingenua, en los 24 meses de validación.

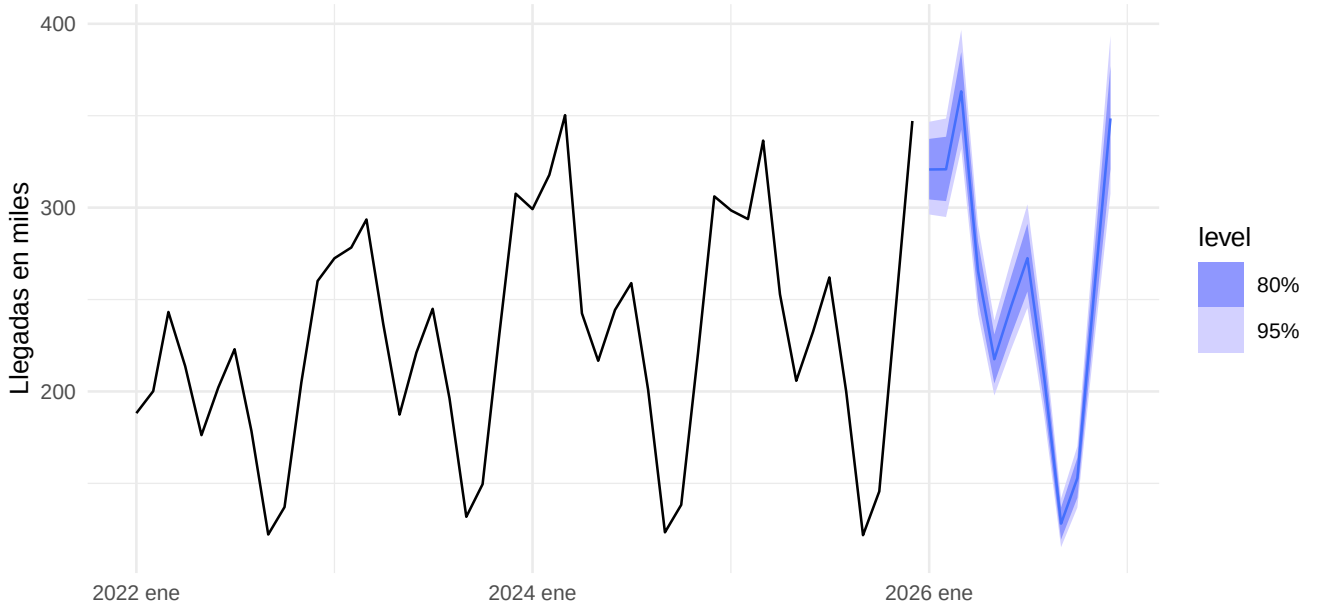


Fuente: elaboración propia.

La Figura 4 muestra dónde se separa cada uno. Los dos siguen bien la forma del año: suben en temporada alta y bajan en setiembre y octubre. La diferencia está en el nivel. El ingenuo repite el año anterior y por eso se queda corto o se pasa cuando el turismo cambia de escalón, mientras que el modelo ajusta ese nivel. Confirma lo dicho antes: el calendario es la parte fácil, lo difícil es acertarle a cuánto creció el turismo.

Pronóstico para los próximos 12 meses

Figura 5: Pronóstico de llegadas internacionales con intervalos de predicción de 80 % y 95 %. La vista se acerca a partir de 2022 para que el pronóstico sea legible.



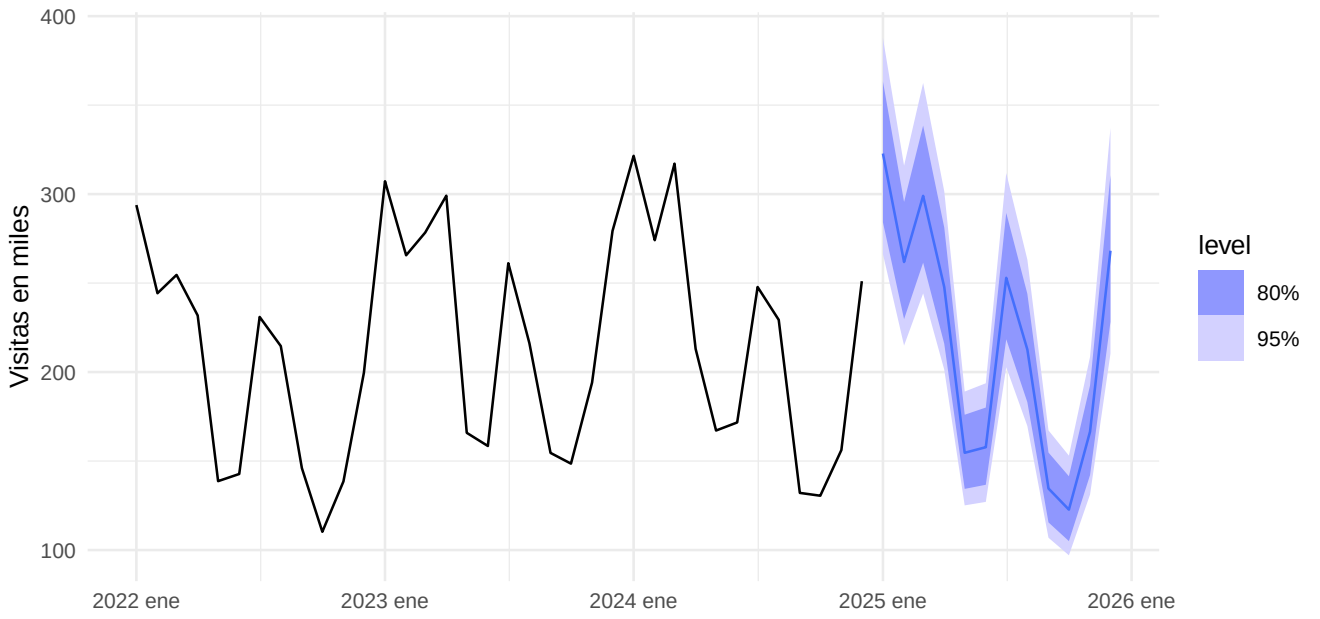
Fuente: elaboración propia.
Fuente: elaboración propia.

La Tabla 4 y la Figura 5 resumen el pronóstico. El total proyectado para los próximos doce meses es de 3 098 023 llegadas, contra 2 943 991 en los últimos doce meses observados: una variación de 5.2 %.

Lo que más conviene mirar no es ese número sino el ancho del intervalo. En promedio, el intervalo de 95 % se extiende alrededor de 10.0 % hacia cada lado del pronóstico. Es un rango amplio, y es honesto que lo sea: con pocos años de datos posteriores al quiebre, la incertidumbre real es grande.

La implicación práctica es que el resultado sirve para planificar escenarios, no para comprometer cifras. Para quien tiene que decidir cuánto personal contratar en temporada alta, el dato útil es que el rango se mantiene, no que el punto central sea exacto.

Figura 6: Pronóstico de visitas totales a áreas silvestres protegidas con intervalos de 80 % y 95 %. La vista se acerca a partir de 2022.



Para las áreas silvestres (Figura 6) el total proyectado a doce meses es de 2 601 445 visitas, una variación de -0.4 % respecto a los últimos doce meses observados, es decir prácticamente el mismo nivel.

El intervalo acá es de 21.3 % a cada lado, más del doble de ancho que el de las llegadas. Esa diferencia no es casual y resume todo lo dicho antes: esta serie es más estacional, su entrenamiento depende más de datos rellenados y su modelo no superó a la referencia ingenua. El intervalo está reflejando una incertidumbre que es real.

La implicación práctica es que estos dos pronósticos no merecen el mismo grado de confianza. El de llegadas se puede usar para planificar. El de áreas silvestres sirve para dar un orden de magnitud y poco más, y conviene presentarlo siempre acompañado de su rango.

Limitaciones

1. **Buena parte del entrenamiento no son datos reales:** los 34 meses rellenados representan 25.8 % del periodo de ajuste en las llegadas y 28.3 % en las áreas silvestres. El pronóstico describe lo esperable si la recuperación sigue la dinámica previa, no un escenario con nuevos choques. La validación mostró que esta limitación tiene consecuencias medibles: es la explicación más razonable de que en las áreas silvestres ningún modelo superara al método ingenuo.
2. **El régimen nuevo tiene pocos años:** solo se cuenta con datos reales posteriores a 2022, o sea dos o tres ciclos estacionales completos. Es poco para estimar con firmeza una estacionalidad que, como mostró la Tabla 3, ya cambió una vez.
3. **Son modelos univariantes:** cada serie se explica solo con su propio pasado. No entran tipo de cambio, conectividad aérea, precios ni actividad económica de los países emisores. Si alguna de esas variables se mueve con fuerza, el modelo no lo puede anticipar.
4. **La composición del turismo cambió y podría volver a cambiar:** el modelo supone que la mezcla de visitantes se mantiene. Si el mercado terrestre centroamericano se recupera, el patrón estacional volvería a moverse.
5. **Las dos series se analizaron por separado y no se afirma causalidad:** que suban y bajen juntas se explica por un calendario común, no porque una determine a la otra. Son datos agregados por mes: no identifican personas ni permiten seguir a un mismo visitante.
6. **La validación usa una sola ventana de 24 meses:** una evaluación con origen móvil, que repite el ejercicio desplazando el punto de corte y promedia los errores, daría una medida más estable (Hyndman y Athanasopoulos, 2021). No se hizo por tiempo y queda pendiente.
7. **El relleno pudo sustituirse por variables de intervención:** conservar los meses reales de la pandemia y marcarlos con una variable indicadora, siguiendo a Box y Tiao (1975), evitaría introducir valores estimados en el entrenamiento. Es la mejora más clara que se identifica para una versión posterior de este trabajo.

Bibliografía

Bates, J. M., y Granger, C. W. J. (1969). The combination of forecasts. *Operational Research Quarterly, 20*(4), 451-468.

Box, G. E. P., y Tiao, G. C. (1975). Intervention analysis with applications to economic and environmental problems. *Journal of the American Statistical Association, 70*(349), 70-79.

Clemen, R. T. (1989). Combining forecasts: A review and annotated bibliography. *International Journal of Forecasting, 5*(4), 559-583.

Durbin, J., y Koopman, S. J. (2012). *Time series analysis by state space methods* (2.a ed.). Oxford University Press.

Hyndman, R. J., y Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3.a ed.). OTexts. https://otexts.com/fpp3/

Hyndman, R. J., y Khandakar, Y. (2008). Automatic time series forecasting: The forecast package for R. *Journal of Statistical Software, 27*(3), 1-22.

Hyndman, R. J., y Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting, 22*(4), 679-688.

Hyndman, R. J., Koehler, A. B., Ord, J. K., y Snyder, R. D. (2008). *Forecasting with exponential smoothing: The state space approach*. Springer.

Instituto Costarricense de Turismo. (2025). *Llegadas internacionales de turistas a Costa Rica, 2009-2025*. Departamento de Estadística Turística. https://www.ict.go.cr/es/estadisticas.html

Instituto Costarricense de Turismo. (2025). *Indicador de visitas a las áreas silvestres protegidas*. Elaborado con datos de la Gerencia de Áreas Silvestres Protegidas del SINAC. https://www.ict.go.cr/es/estadisticas.html

Anexos

Tabla 3: Índice estacional de las llegadas internacionales antes y después de la pandemia.

Mes	2013-2019	2023-2025	Diferencia
Ene	135.3	121.2	-14.1
Feb	117.3	123.9	6.6
Mar	124.8	136.4	11.6
Abr	100.9	102.0	1.1
May	82.8	84.9	2.1
Jun	94.2	97.2	3.0
Jul	107.0	106.7	-0.3
Ago	88.6	83.2	-5.4
Set	64.6	52.6	-12.0
Oct	69.9	60.5	-9.4
Nov	92.3	97.5	5.2
Dic	122.4	133.8	11.4

Fuente: elaboración propia con datos del Instituto Costarricense de Turismo.

Tabla 4: Pronóstico mensual de llegadas internacionales con intervalo de predicción de 95 %.

Mes	Pronóstico	Límite inferior	Límite superior
2026 ene	320 764	296 293	346 698
2026 feb	320 864	294 901	348 480
2026 mar	363 248	331 980	396 642
2026 abr	265 527	242 132	290 553
2026 may	217 526	197 827	238 640
2026 jun	246 361	222 926	271 571
2026 jul	272 516	245 422	301 763
2026 ago	207 384	186 503	229 946
2026 sept	128 100	115 291	141 931
2026 oct	152 859	136 888	170 168
2026 nov	254 352	225 911	285 360
2026 dic	348 523	307 548	393 402

Fuente: elaboración propia.

Repositorio del proyecto: github.com/Jerald-vm/Grupo_1_Herramientas